UAV-TAlign-12K：面向跨视场无人机红外-可见光对齐的场景级可靠性基准

匿名作者

中文审阅稿，与英文投稿稿同步

摘要

跨视场红外-可见光对齐是无人机巡检、夜间感知与多模态场景理解中的核心能力。本文提出 UAV-TAlign-12K：一个基准规模的数据集，包含从 15 个工业与自然场景采集的 6,039 对同步 RGB 与热红外图像，并提供经过完整性检查的 6,037 对正式评测划分。该基准从三个互补层级组织评测：成对单应性证据、场景级共识，以及可靠性–覆盖率运行分析。七种代表性方法涵盖经典关键点流程、红外-可见光专用匹配方法，以及现代稠密或学习型匹配器。成对证据在整体上具有很高可用性：RIFT2、RoMa 与 raw MINIMA 在全部 6,037 对图像上均能生成单应性，而 LoFTR 与 XoFTR 的可用率均超过 99%。在此基础上，UAV-TAlign 结合渐进式证据调度、几何引导帧加权、鲁棒场景共识与跨模态质量验证。该框架为全部 15 个场景估计变换，并在规范运行点识别出 9 个高置信对齐产品，覆盖 74.4% 的评测图像对。在五折留帧分析中，各场景平均位移的中位数为 1.39 像素；受控平移、旋转与尺度扰动则使平均联合质量信号逐步下降。UAV-TAlign-12K 为基准规模、置信度感知的无人机红外-可见光对齐研究建立了可复现基础。

主要要点

- UAV-TAlign-12K 提供 6,039 对同步跨视场无人机 RGB-红外图像。
- 七种基线表明，成对单应性证据已具有广泛可用性。
- UAV-TAlign 生成 15 个场景变换，并识别出 9 个高置信场景产品。
- 重采样和受控扰动检验共识稳定性与质量诊断敏感性。

关键词：红外-可见光数据集；无人机影像；多模态配准；对齐基准；场景级可靠性

1 引言

红外-可见光对齐是无人机巡检、夜间监测与多模态热感知中的基础能力。可见光影像提供语义与结构细节，而热红外影像在光照变化和低照度条件下提供互补信息。两种模态

的结合已经支撑了多光谱检测、跟踪以及复杂运行环境中的航空感知 [1–8]。因此，要将两路数据视为一个统一的传感系统，而非彼此独立的观测，就必须准确恢复跨传感器几何关系。

无人机采集引出了一个具有自身特点的对齐问题。跨视场光学系统、不一致的传感器分辨率、变化的视角以及变焦会使同一场景在可见光和红外通道中呈现不同几何形态。时间同步采集保留了这些跨传感器差异，并不对图像进行几何配准。红外图像渲染方式以及昼夜外观变化还会进一步改变局部纹理和对比度。因此，一段飞行序列会提供异质的几何证据：不同图像对在空间支撑、单应性稳定性以及跨模态一致性方面可能存在显著差异。有效的对齐方法需要将这些证据整合为可服务于下游感知任务的场景变换。

现代对应关系估计方法已经显著提高了成对证据的可用性。LoFTR、LightGlue、DKM、RoMa、XoFTR 和 MINIMA 等 Transformer、稠密与多模态匹配器，能够在越来越困难的外观变化下恢复对应关系 [9–16]。近期无人机对齐基准也引入了合成变换监督与直接几何评测 [17]。这些进展建立了强大的成对匹配基础，同时也提出了更高层次的基准问题：应如何在真实无人机场景尺度上整合并评估质量不一的逐帧估计？

本文通过 UAV-TAlign-12K 回答这一问题。该基准包含来自 15 个工业与自然场景的 6,039 对真实采集跨视场无人机红外-可见光图像。正式评测划分包含 6,037 对经过完整性检查的图像，覆盖白天、夜间与低照度采集，灰度与伪彩红外渲染，以及广角、变焦和常规无人机视图。该基准定义了三个互补的评测轨道：成对评测衡量单应性证据可用性；场景级评测衡量多帧共识产品；可靠性–覆盖率曲线刻画可选择的运行区间。这个层级结构将对应关系生成与无人机感知系统所需的场景产品联系起来。

图 1 展示代表性同步图像对及正式评测划分覆盖的条件。

UAV-TAlign 是该基准的参考框架。它构建在强成对匹配器之上，并结合渐进式证据调度、几何引导帧加权、鲁棒场景共识和跨模态质量验证。在正式评测划分上，红外专用方法和现代匹配器均能提供高可用性的成对单应性。UAV-TAlign 将这些证据转化为全部 15 个场景的变换，并在规范运行点识别出 9 个高置信场景产品，覆盖 74.4% 的评测图像对。受控扰动和留帧重采样分别从几何敏感性与证据稳定性两个方面刻画质量诊断量与共识变换。

本文的主要贡献包括：

- 提出 UAV-TAlign-12K，一个包含 15 个多样化场景、6,039 对同步图像及 6,037 对完整性检查评测划分的真实跨视场无人机红外-可见光基准。
- 构建覆盖成对单应性证据、场景级共识与可靠性–覆盖率分析的多层评测协议，并通过条件感知诊断、重采样稳定性和受控扰动对其进行验证。
- 提出 UAV-TAlign 参考框架，通过渐进式证据调度、鲁棒共识和跨模态质量验证，将强成对证据转化为高置信场景产品。

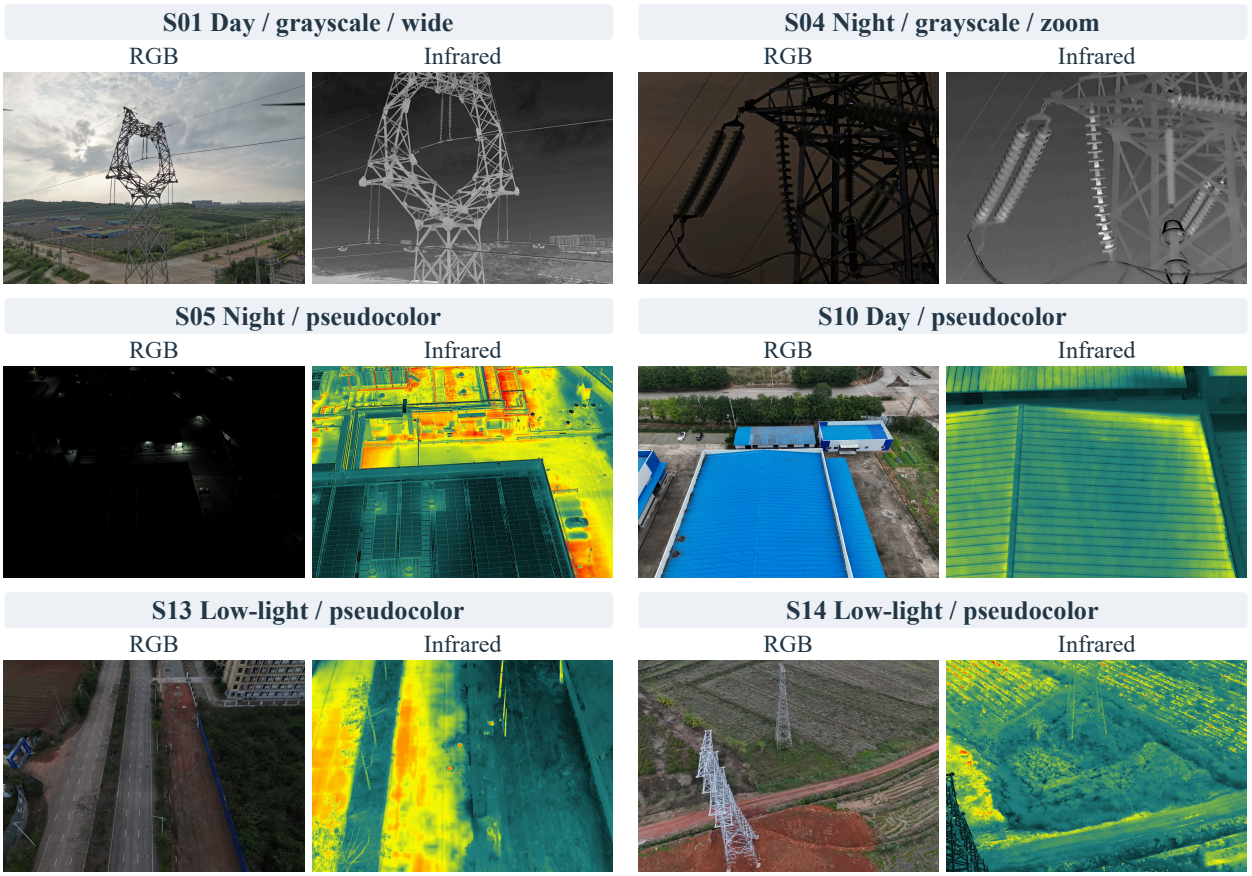

图 1: UAV-TAlign-12K 概览。同一 M350/H30T 平台采集的代表性 RGB-红外图像对覆盖白天、夜间与低照度，灰度与伪彩，以及广角和变焦视图。数据集包含 6,039 对同步影像，其中 6,037 对构成经过完整性检查的正式评测划分。

2 相关工作

2.1 跨模态对应关系与几何估计

经典配准流程通常结合局部特征提取、描述子匹配与鲁棒模型估计。尺度空间、二进制以及非线性扩散特征为多种成像条件提供了高效的几何参考 [18–23]。RANSAC 及其面向精度改进的后续方法，仍是将含噪对应关系转化为几何模型的核心技术 [24–27]。针对红外-可见光影像，RIFT 等辐射变化不敏感方法提高了描述子在模态特有外观变化下的重复性 [28]。RIFT2 通过改进旋转不变构造降低计算开销 [29]。这些方法为区分“对应关系质量”和“后续场景聚合”提供了可解释的基础。

学习型对应关系方法同时扩展了成对证据的鲁棒性和空间密度。早期可训练检测器与描述子建立了数据驱动的局部表示 [30–38]。随后，图推理、Transformer 与稠密形变预测使方法能够直接处理低纹理、重复结构和大幅外观变化 [9–14, 39–43]。XoFTR 与 MINIMA 进一步面向可见光-热红外或更广泛的多模态对应关系 [15, 16]。UAV-TAlign 在这些进展之上，将成对匹配器视为场景级几何流程中的证据生成器。

2.2 红外-可见光对齐

红外-可见光配准涵盖基于特征的匹配与学习型对应关系估计 [15, 16, 28, 29]。在更广泛的图像对齐与拼接任务中，学习型方法从训练数据中估计变换或重建对齐影像 [44, 45]。无人机双传感器影像还叠加了跨分辨率光学、视点位移、红外图像渲染变化和光照变化。这些条件推动了专用成对方法和无人机数据资源的发展。

UAVMatch 为可训练无人机对齐提供合成变换监督和受控几何指标 [17]。ATR-UMMIM 提供 7,969 组真实无人机可见光–红外–已配准可见光三元组，并包含条件属性和半自动像素级参考 [46]。UAV-TIRVis 提供 80 对人工配准的航空热红外-可见光图像，用于直接图像域评测 [47]。UAV-TAlign-12K 通过 6,039 对真实采集跨视场数据和多帧协议对这些资源形成补充，该协议把成对单应性、场景共识与可靠性–覆盖率运行分析联系起来。

2.3 无人机多模态基准与场景级评测

KAIST、FLIR、LLVIP、M3FD、DroneVehicle、VTUAV、LasHeR 和 Anti-UAV 等多模态数据集推动了检测、融合、跟踪和低照度感知的发展 [1–8]。这些成果体现了同步可见光与红外感知的价值。对齐任务还需要输出明确的几何产品，因此适合采用超越孤立对应点数量的评测方式。

UAV-TAlign-12K 定义了成对、场景和运行曲线三个评测轨道。成对轨道衡量单应性证据的可用性与支撑度；场景轨道衡量多组逐帧估计如何形成共识变换；运行曲线则使用固定、可解释的跨模态诊断对场景产品排序。该设计将经典方法、红外专用方法和现代学习型证据生成器纳入统一的真实采集协议，并以 UAV-TAlign 作为场景级参考框架 [48, 49]。

3 UAV-TAlign-12K 与评测协议

3.1 数据集范围

UAV-TAlign-12K 是面向真实无人机红外-可见光对齐的基准。数据集包含 6,039 对同步 RGB-红外图像，对应 15 个场景中的 12,078 张图像。正式评测划分包含 6,037 对经过完整性检查的图像，共计 12,074 张。数据覆盖跨视场与跨分辨率感知条件，包括白天、夜间和低照度采集，灰度与伪彩红外图像渲染，以及广角、变焦和常规无人机视图。

所有期刊规模实验均使用同一个版本化 manifest。UAV-TAlign-1K-Lite 保留为固定的开发与消融子集，而 UAV-TAlign-12K 用于本文的基准规模评测。正式划分包含 7 个白天场景、5 个夜间场景和 3 个低照度场景，同时包含 8 个灰度红外场景和 7 个伪彩红外场景。变电站场景族中的成对广角与变焦视图提供了受控的跨视场比较。

3.2 采集与整理

UAV-TAlign-12K 的采集时间跨度为 2024 年下半年至 2026 年上半年，覆盖中国南部的工业与自然场景。全部场景均使用同一套 DJI Matrice 350 RTK 平台和 Zenmuse H30T

表 1: UAV-TAlign-12K 与代表性红外-可见光及无人机多模态资源的定位比较。UAVMatch 表示采用合成变换监督的无人机对齐基准。

资源	数据与对齐参考	规模	评测重点
KAIST / FLIR / LLVIP / M3FD	地面或混合 RGB-红外数据；成对或已对齐影像	依数据集而定	检测、融合、低照度感知
DroneVehicle / VTUAV / LasHeR / Anti-UAV	无人机或跟踪型 RGB-红外数据；任务标注	依数据集而定	多模态检测或跟踪
UAVMatch [17]	从无人机数据构造合成仿射 / 单应性监督	81K 训练 / 15K 测试对	变换回归与几何指标
ATR-UMMIM [46]	含已配准可见光图像的真实无人机三元组；半自动像素参考	7,969 个三元组	成对配准与条件属性
UAV-TIRVis [47]	真实航空热红外-可见光图像对；人工配准	80 对	图像域配准质量
UAV-TAlign-12K	真实采集跨视场无人机图像对；多帧场景协议	6,039 个候选 / 6,037 个评测对	成对证据、场景共识、运行覆盖率

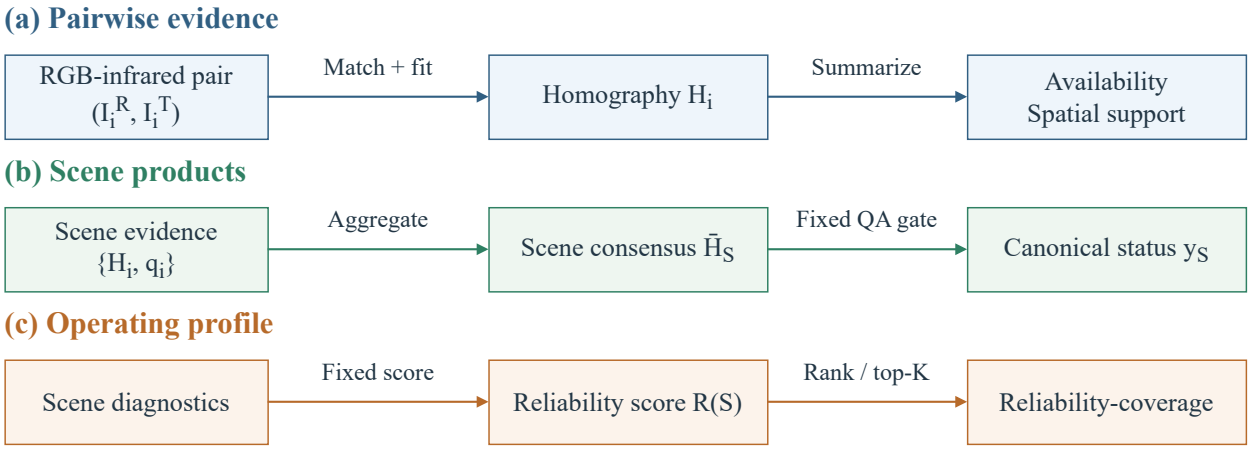

图 2: 三个互补的基准评测轨道。首先评测成对单应性证据，再进行多帧聚合；固定规范门控选择场景产品，独立评分用于覆盖率分析中的场景排序。所有轨道使用同一正式 manifest。逐场景数量与采集属性详见附录 B。该可编辑示意图使用 OpenAI Codex 辅助制作。

多传感器载荷采集。其非制冷氧化钒微测辐射热计工作在 8–14 μm 长波红外（LWIR）波段 [50]。本文中 UAV-TAlign-12K 的“红外图像”指该热成像通道输出的灰度或伪彩渲染图像。集成载荷在时间上自动同步可见光与红外采集；图像保留原生跨传感器几何关系，不进行人工几何对齐。飞行方式包括悬停和航线式采集，所用无人机完成实名登记，飞手具有 CAAC 资质，并在允许飞行的空域内执行任务。

发布的数据流保留 H30T 原生采集模式。广角相机静态图像分辨率为 4032×3024，变焦相机静态图像为 3664×2748，红外图像为 1280×1024。场景 01 和 02 的 3840×2160 静态图像是在 H30T 录像期间触发拍照获得。场景 07 是同步视频抽帧序列，以每秒 2 帧的频率采样，覆盖无人机环绕输电塔一周的完整过程。灰度场景使用 H30T 的 *White Hot* 设置，

伪彩场景使用设备内置的 *Hot Iron* 色板。

数据整理标准在算法评测前冻结，涵盖场景相关性、曝光、对焦和文件完整性。整理后的候选数据集包含 6,039 对同步图像，完整性审计进一步定义了 6,037 对正式评测划分。筛选过程不使用匹配器输出、对齐估计或质量分数。

发布准备阶段移除嵌入式元数据并规范化文件名，同时保持图像像素不变。RGB 与红外文件通过共享的 H30T 采集键关联，按采集时间与序列索引排序，并赋予共同的六位图像对标识。发布过程不进行缩放、裁剪、旋转、重压缩或图像增强。数据集归南宁师范大学与广西大学共同所有，并计划采用知识共享署名 4.0 国际许可协议发布。

3.3 数据组织

每个场景均包含独立的 `rgb/` 与 `thermal/` 目录，配对样本具有相同的文件名主干。正式 manifest 记录场景标识、图像对标识、光照条件、红外图像渲染、视图类型和场景标签。一个场景用于汇集具有共同地点或目标语境及采集条件的帧，可以来自连续序列，也可以来自同一场景定义下的多次架次。场景 07 是明确记录的单次环绕视频序列。

同一个 manifest 支撑全部成对、场景和条件分析，并把每一项报告结果映射回对应场景与图像对标识。

3.4 多层评测协议

基准定义三个互补轨道。轨道 A 独立评测全部 6,037 对图像，衡量成对单应性证据的可用性与支撑度。轨道 B 将逐帧估计聚合为场景变换，并报告规范定义的高置信场景产品集合。轨道 C 使用固定、可解释的可靠性分数对场景排序，从而构建覆盖率感知的运行曲线。

三个轨道共同把匹配器输出与可部署场景几何联系起来。成对指标刻画证据生成，场景级指标刻画多帧共识，运行曲线则反映场景质量变化时产品覆盖率的演变。

3.5 无标注场景一致性诊断

该协议测量应用场景共识变换后的跨模态一致性，并与尺寸匹配的红外参考进行比较。参考图像仅将红外图缩放到 RGB 评测网格，不估计对齐变换。诊断量包括边缘重叠增益、梯度 NCC 增益、梯度一致性改善帧比例、严重基线相对离群点数量与比例、接受帧支撑、单应性离散度，以及鲁棒剔除比例。附录 A 给出统一使用的参考、探针帧、归一化与汇总约定。

这些信号共同刻画跨模态改善、几何支撑和共识稳定性，并通过统一评测接口支撑规范产品选择、条件感知分析和可靠性–覆盖率可视化 [48, 49]。

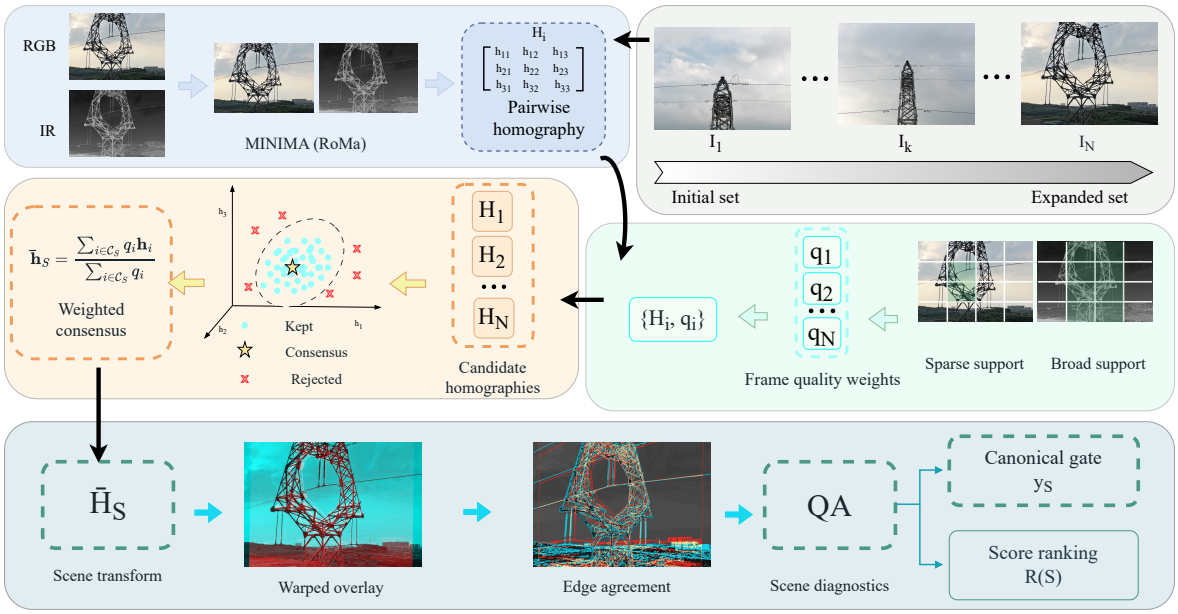

图 3: UAV-TAlign 工作流程。渐进式证据选择为鲁棒场景共识提供成对单应性与帧质量权重，跨模态 QA 输出规范产品决策及独立的评分排序。图像示例取自 S02；支撑网格与参数空间簇用于示意计算过程。该可编辑示意图的布局使用 OpenAI Codex 辅助修订。

4 UAV-TAlign 参考框架

4.1 问题定义

UAV-TAlign 用于实例化 UAV-TAlign-12K 的场景级评测轨道。对每个场景，输入是一组配对的无人机 RGB 与红外帧 $S = \{(I_i^R, I_i^T)\}_{i=1}^N$，其中上标 R 和 T 分别表示 RGB 与热红外。视点变化、跨分辨率感知、红外图像外观差异和光照变化会使各帧估计具有异质的支撑质量。目标是恢复一个从红外到 RGB 的场景单应性，并刻画其运行置信度。

该定义把配准表述为多帧证据整合问题，而非单对图像选择问题。框架需要把质量不一的逐帧估计转化为几何稳定且跨模态一致的场景变换。对于一个选定图像对，从红外到 RGB 的证据表示为作用于齐次图像坐标的单应矩阵 $H_i \in \mathbb{R}^{3\times3}$：

$$\tilde{\mathbf{p}}_{ij}^R \sim H_i \tilde{\mathbf{p}}_{ij}^T, \qquad H_i = \arg\min_H \sum_{j\in\mathcal{I}_i} \rho\Big(\big\|\pi(H\tilde{\mathbf{p}}_{ij}^T) - \mathbf{p}_{ij}^R\big\|_2^2\Big), \tag{1}$$

其中，$\mathcal{I}_i$ 表示鲁棒估计得到的内点集合，$\pi(\cdot)$ 将齐次坐标转换为图像坐标，$\rho(\cdot)$ 是鲁棒估计损失。场景级问题是在证据集合 $\{H_i\}$ 上估计共识变换 $\bar{H}_S$，并赋予其规范产品状态。

4.2 成对证据生成器

UAV-TAlign 使用预训练多模态匹配器生成成对证据。参考实现采用 MINIMA 的 RoMa 分支，其余阶段则可以接收任意兼容匹配器输出的单应性与几何诊断量 [14, 16]。

4.3 渐进式证据调度

UAV-TAlign 从一个紧凑、均匀分布的帧子集开始，并以确定性阶段逐步扩展支撑集合。调度规模随场景长度变化，必要时可以覆盖完整序列。当接受支撑、共识稳定性和跨模态质量条件满足时停止扩展；否则评测下一阶段子集。不超过 300 对图像的场景使用全部图像对。更大场景从约 15% 的图像对开始，以 15 个百分点为步长扩展到 50%，必要时再使用全场景。12 帧设置控制代表性 QA 探针，不是匹配证据的固定上限。附录 A 给出支撑与停止规则。

在每个阶段内，均匀分布采样提供可复现的时间或索引覆盖。随机选择变体通过独立的多随机种子敏感性分析进行评测。

4.4 几何引导帧加权

对于每个选定图像对，匹配器产生跨模态对应关系和逐帧单应性估计。UAV-TAlign 测量匹配数量、内点支撑、内点率、重投影误差和空间覆盖率。当这些统计量满足几何质量准则时，对应帧进入场景候选池。该处理遵循标准单应性估计与鲁棒拟合方法 [24–27]。

每个接受帧还会获得一个连续质量权重。该权重综合内点率、空间覆盖率、重投影质量、匹配器置信度以及内点支撑，使具有更强几何依据的单应性在场景聚合中具有更大影响。固定帧质量权重为：

$$\begin{aligned} q_i = 0.42 r_i + 0.28 c_i + \frac{0.15}{1 + \max(e_i, 0)} \\ + 0.10 m_i + 0.05 \tanh(n_i/300), \end{aligned} \tag{2}$$

其中，r_i 是内点率，c_i 是空间匹配覆盖率，e_i 是以 RGB 图像像素为单位的平均内点重投影误差，m_i 是平均匹配置信度，n_i 是内点数量。所有 UAV-TAlign-12K 评测均使用固定系数。

4.5 鲁棒场景共识

在获得足够的逐帧单应性后，UAV-TAlign 构建鲁棒场景共识。首先将单应性映射到参数空间，以中位数作为中心参考，并采用中位数绝对偏差（MAD）准则剔除不稳定估计；随后使用上述帧质量分数对保留单应性进行加权聚合。将 H_i 的右下元素归一化为一后，令 $\mathbf{h}_i$ 包含其八个自由分量，则共识集合为：

$$\begin{aligned} \mathbf{h}_S^{\mathrm{med}} &= \mathrm{median}_{j \in \mathcal{A}_S}(\mathbf{h}_j), \\ d_i &= \left\| \mathbf{h}_i - \mathbf{h}_S^{\mathrm{med}} \right\|_2, \\ m_d &= \mathrm{median}_{j \in \mathcal{A}_S}(d_j), \\ s_d &= \mathrm{median}_{j \in \mathcal{A}_S} |d_j - m_d| + 10^{-9}, \\ \mathcal{C}_S &= \{ i \in \mathcal{A}_S : d_i \le m_d + 2.5 s_d \}. \end{aligned} \tag{3}$$

其中，$\mathcal{A}_S$ 是鲁棒共识前的接受帧集合。场景变换通过质量加权聚合得到：

$$\bar{\mathbf{h}}_S = \frac{\sum_{i\in\mathcal{C}_S} q_i \mathbf{h}_i}{\sum_{i\in\mathcal{C}_S} q_i}, \qquad \bar{H}_S = \mathrm{mat}(\bar{\mathbf{h}}_S). \tag{4}$$

框架同时记录聚合变换周围的稳定性诊断，包括相对于聚合结果的单应性离散度，以及被鲁棒剔除的逐帧估计比例。这些诊断量把共识形成过程与最终场景产品决策联系起来。

4.6 跨模态场景验证

最后阶段融合几何支撑与跨模态场景一致性。UAV-TAlign 在代表帧上测量共识变换的边缘重叠增益、梯度 NCC 增益、改善帧比例和严重相对离群点。同时记录接受帧支撑、平均内点率、平均重投影误差、空间覆盖率、相对于聚合变换的离散度，以及鲁棒剔除比例。

规范决策将接受支撑与两条路径之一结合：主要边缘/梯度检验，或额外约束几何与离群点的基线感知路径。一个固定、可解释的评分汇总归一化诊断量，用于运行曲线可视化：

$$\begin{aligned} R(S) = 100\big(&0.25\hat{a}_S + 0.25\hat{o}_S + 0.20\hat{j}_S \\ &+ 0.15\hat{e}_S + 0.10\hat{g}_S + 0.05\hat{z}_S\big). \end{aligned} \tag{5}$$

每个带帽分量均位于 $[0,1]$，较大的值依次代表更强的接受支撑、离群点控制、共识保留、边缘改善、梯度改善与几何支撑。附录 A.3 列出全部归一化和截断常数。规范决策要求满足最低接受帧假设数量，并通过两条固定验证路径之一：

$$y_S = \mathbb{1}[N_S \geq N_{\min}]\,\mathbb{1}[L_S \vee W_S]\,. \tag{6}$$

其中，N_S 为接受帧数，$N_{\min}$ 是随场景规模确定的支撑阈值。L_S 表示主要边缘/梯度路径，W_S 在基于尺寸的初始化条件下联合接受支撑、共识几何、相对离群点控制和梯度改善。附录 A.2 给出两条路径的具体定义。$R(S)$ 用于可靠性–覆盖率分析中的场景排序，y_S 则定义规范的高置信对齐产品集合。

图 4 在一组匹配场景对照上揭示内部证据流：即使接受帧数量相同，引入共识剔除与跨模态离群点后，仍可得到不同的场景产品决策。

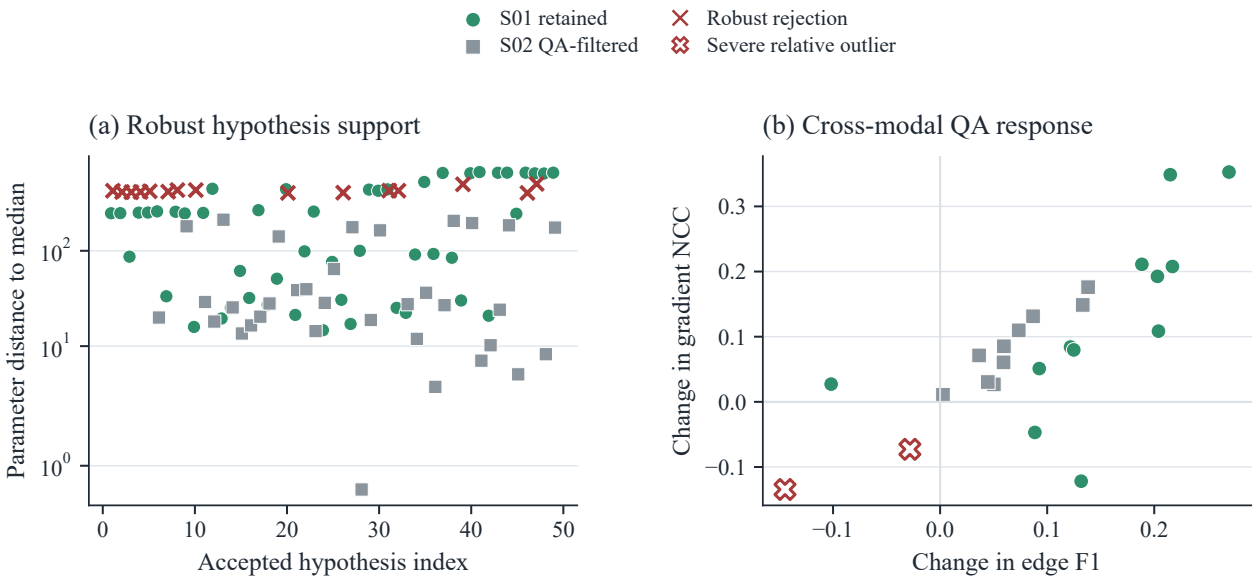

图 4: S01/S02 场景对照中的鲁棒共识与跨模态质量验证。（a）参数空间距离标识中位数/MAD 过滤剔除的假设；（b）QA 探测帧呈现不同的边缘/梯度响应及严重相对离群点。S01 和 S02 的接受支撑相同（49/50），但规范结果不同。

5 实验设置

5.1 基线方法

本文评测七种代表性基线，不针对 UAV-TAlign-12K 进行特定适配；学习型方法均采用公开预训练权重。基线覆盖三个方法类别。SIFT 与 AKAZE 构成经典关键点参考，随后均进行鲁棒单应性估计。RIFT2 通过 Python 实现提供红外-可见光专用经典参考 [29, 51]。现代方法包括 Kornia LoFTR、RoMa outdoor、XoFTR-640 和 raw MINIMA [10, 14–16]。

raw MINIMA 使用 `minima_roma` 检查点族和完整 RoMa 分支。RoMa 使用公开 outdoor full 模型，XoFTR 使用 640 分辨率可见光-热红外检查点，LoFTR 使用 Kornia 的公开 outdoor 预训练模型。统一推理封装在保留各预训练模型的同时，对图像输入输出、模型输出、单应性拟合和结果格式进行标准化。

5.2 几何拟合与部署配置

所有成对方法均使用 USAC-MAGSAC 估计单应性。共享配置使用 3.0 像素重投影阈值、0.999 置信度和 10,000 次最大迭代；RIFT2 保留单独指定的 5.0 像素配置。所有方法均采用 4×4 网格度量空间匹配覆盖率。附录 A.4 定义拟合诊断量及其汇总方式。

RIFT2 使用冻结的 resize-aware 配置：`max_dim=1200`、`npt=2000`、`patch_size=64`、Lowe ratio 0.95，并采用 5.0 像素重投影阈值的 USAC-MAGSAC。LoFTR 使用最长图像边为 1200 的 resize-aware 推理并启用自动混合精度。运行时间和拟合诊断量均在这些声明的部署配置下报告。

5.3 协议验证

本文在冻结的正式输出上开展两项受控实验。五折留帧分析以确定性方式划分接受帧假设，每次留出一折，重新计算场景共识，并测量其相对完整证据变换的网格位移。受控敏感性实验对每个场景的 3 个代表帧施加平移、旋转和尺度扰动，标称严重度为 2、5、10、20 和 40 像素。实验记录边缘重叠与梯度 NCC 响应，同时保持规范决策不变。

期刊规模实验在配备 NVIDIA RTX 4090 的工作站上、相互隔离的 Python 环境中完成。主环境采用 Python 3.10、PyTorch 2.0.1、torchvision 0.15.2、CUDA 11.8、OpenCV 4.11.0 和 Kornia 0.6.11；RIFT2 使用独立的 Python 3.11 环境。所有实验均使用正式 manifest、固定模型权重或接口、独立输出目录以及只读的原始数据目录。

实现与可视化辅助。 OpenAI Codex 用于辅助 Python 实现、评测封装、结果汇总及绘图脚本开发。报告数值由版本化脚本基于固定 manifest 和归档运行输出计算。图像面板使用实际采集的无人机影像、冻结的单应矩阵，以及确定性的裁剪、变换和边缘叠加操作；不使用生成式图像模型生成或修改所采集的场景内容。

6 实验结果

6.1 成对红外-可见光单应性证据

在 UAV-TAlign-12K 上，成对红外-可见光单应性证据整体具有很高可用性。表 2 报告完整的 6,037 对正式评测划分。SIFT 和 AKAZE 作为经典关键点参考，单应性可用率分别达到 87.08% 和 94.29%。RIFT2、raw MINIMA 和 RoMa 在每一对评测图像上均能产生单应性，而 LoFTR 与 XoFTR 的可用率均超过 99%。这些结果表明，红外专用方法和现代稠密匹配器均可作为场景级对齐的强证据生成器。

表 2: UAV-TAlign-12K 上的成对红外-可见光单应性证据。IR 与 Cov. 分别为平均内点率和平均候选匹配覆盖率；Reproj. 为单对平均内点残差的中位数（像素）；Time 为单对时间均值（秒）。统计使用有限记录值，详见附录 A.4。这些是互补诊断量，不构成单一质量排名。

方法	H / N	H (%)	IR	Cov.	Reproj.	Time
经典关键点						
SIFT	5257/6037	87.08	0.242	0.627	0.000	4.421
AKAZE	5692/6037	94.29	0.160	0.730	0.105	1.103
红外-可见光经典方法						
RIFT2 (Python, resize-aware)	6037/6037	**100.00**	0.086	0.354	0.121	13.980
现代稠密 / 学习型						
Kornia LoFTR	5984/6037	99.12	0.074	0.895	0.823	0.169
XoFTR-640	5989/6037	99.20	0.089	0.949	1.732	0.647
RoMa outdoor	6037/6037	**100.00**	0.328	0.997	1.741	0.929
raw MINIMA	6037/6037	**100.00**	0.319	1.000	1.773	1.346

不同方法族呈现互补的证据特性。RIFT2 同时实现完整单应性可用率和较低拟合重投

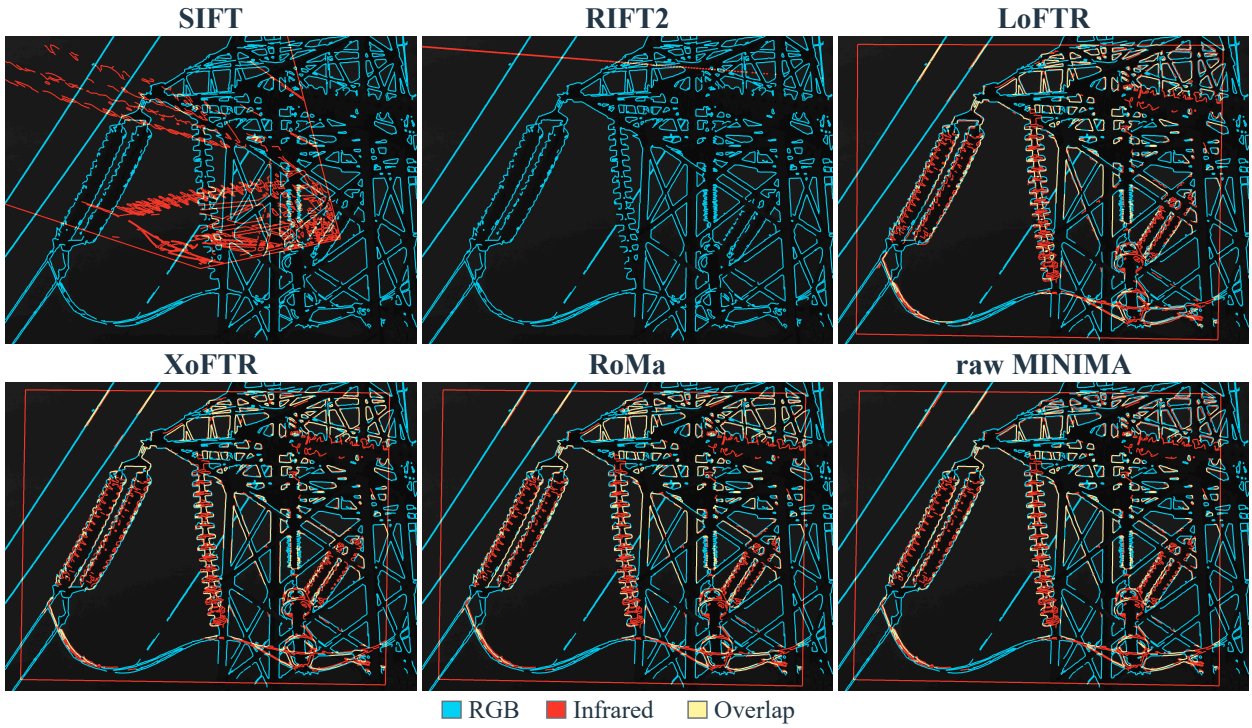

图 5: 六种代表性匹配器在固定图像对 S04/000020 上的单应性证据。所有子图使用同一 RGB 坐标系和边缘显示设置：青色为 RGB 边缘，红色为变换后的红外边缘，浅黄色表示重叠。变换遵循所声明的拟合配置。完整划分上的可用率与覆盖率见表 2。

影误差，而 raw MINIMA 与 RoMa 提供接近完整的空间覆盖。可用性、支撑度和覆盖率共同构成场景级基准轨道的几何背景。

6.2 场景级参考结果

UAV-TAlign 将成对证据转化为全部 15 个场景的变换。在规范运行点，框架识别出 9 个高置信产品，对应 60.0% 的场景覆盖率和 74.4% 的图像对覆盖率。这些产品内部的接受帧支撑为 1491/2304 （64.7%）。全 15 场景的接受支撑为 2473/3847（64.3%）；两项比例对应不同场景集合。

表 3: UAV-TAlign 在 UAV-TAlign-12K 上的规范场景级运行点。图像对覆盖率和接受帧支撑均在 9 个高置信场景产品上计算。

UAV-TAlign 场景级指标	数值
单应性可用	15/15
规范保留场景	9/15
场景覆盖率	60.0%
图像对覆盖率	74.4%
保留集合接受 / 尝试	1491/2304
保留集合接受率	64.7%

图 6 展示代表性规范对齐产品，覆盖不同光照、红外渲染和视图条件。统一裁剪区域和边缘一致性视图使跨模态几何改善能够被直接检查。

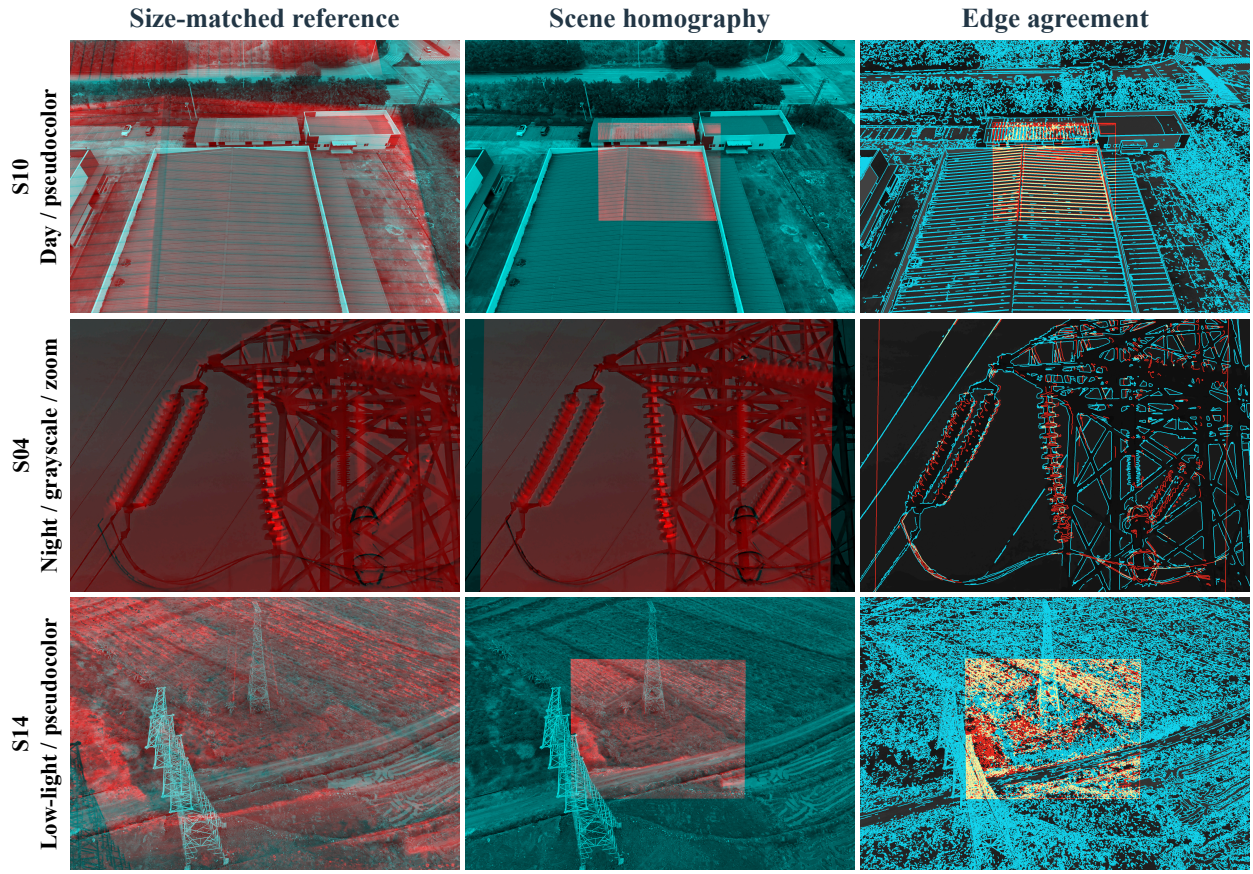

图 6: 规范运行点下的代表性 UAV-TAlign 高置信场景产品。各行覆盖白天、夜间与低照度场景，并包含灰度和设备原生伪彩红外渲染；各列依次展示尺寸匹配参考、场景单应性叠加和边缘一致性，每行采用固定裁剪范围。RGB 和红外输入见图 1；附录 B 给出另一个电塔案例。

6.3 条件感知运行曲线

不同光照条件呈现不同的场景产品和接受支撑特性。白天采集具有最高的场景覆盖率和接受帧比例；夜间采集得到 3/5 个高置信产品；低照度采集在 3 个场景中保持 61.3% 的接受帧比例。这两类互补测量将可用帧支撑与最终场景产品区分开来。

表 4: 按光照条件统计的运行曲线。接受/尝试表示每种条件下所有场景的汇总帧支撑。

条件	保留 / 总场景	场景覆盖率 (%)	接受 / 尝试	接受率 (%)
白天	5/7	71.4	1650/2203	74.9
夜间	3/5	60.0	361/890	40.6
低照度	1/3	33.3	462/754	61.3

图 7 将分析扩展到光照、红外渲染与视图类型，同时报告场景保留率和接受帧支撑。

6.4 可靠性控制的场景选择

匹配场景对照说明了为何成对支撑不能单独决定最终产品集合。图 8 采用一致显示规则比较白天广角/变焦对照。夜间对照与全场景 QA 散点图分别见附录 B。规范产品集中在

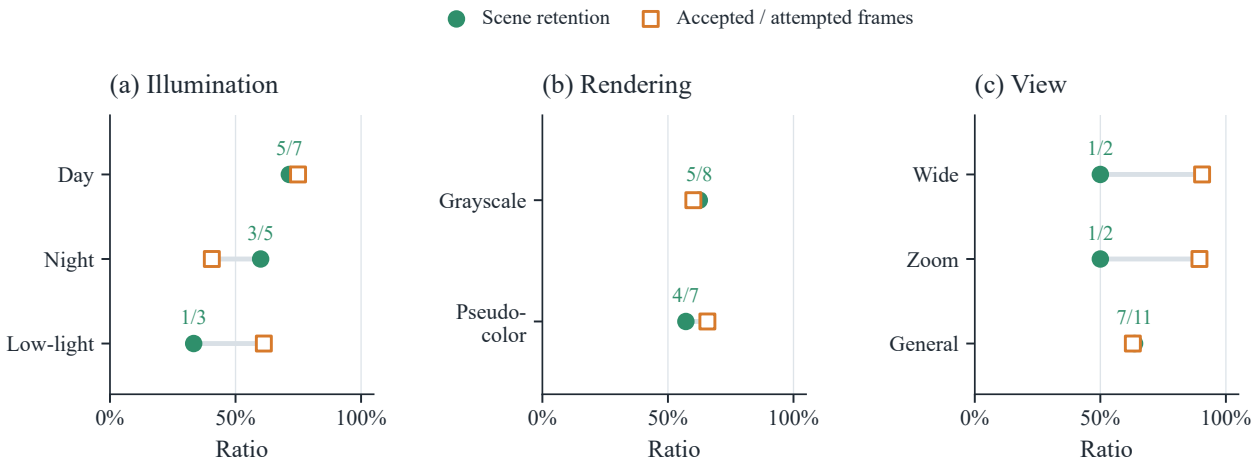

图 7: 按（a）光照、（b）红外渲染、（c）视图类型组织的条件感知运行曲线。实心圆为场景保留率，空心方块为接受/尝试帧支撑；标注给出保留/总场景数。同一场景在不同属性分组中重复出现。

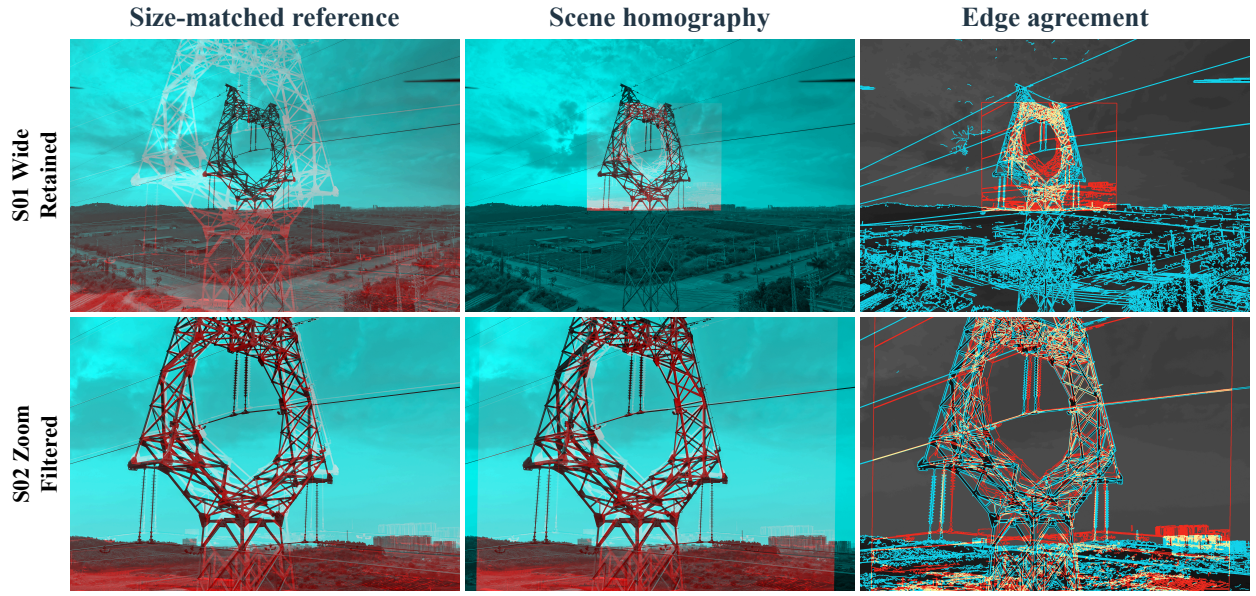

图 8: 白天广角/变焦对照：S01 被规范门控保留，S02 被 QA 过滤。各列依次展示尺寸匹配参考、估计的场景单应性和边缘一致性。S02 变换仅用于检查，不属于保留产品。规范标签描述的是场景级决策，而非对所展示单帧分别作出的决策。

低离群区域，而接受帧比例横跨保留场景与质量过滤场景。

6.5 可靠性–覆盖率运行曲线

固定的跨模态验证规则定义规范产品集合，可解释分数则对场景排序以形成离散的可靠性–覆盖率运行点。图 9 绘制基于分数排序的曲线，并叠加固定的规范运行点。

在规范运行点，UAV-TAlign 识别出 9 个高置信产品，覆盖 60.0% 的场景和 74.4% 的评测图像对，平均严重离群点比例为 0.009。随着更多场景进入选择集合，分数排序运行点展现诊断量之间的取舍。

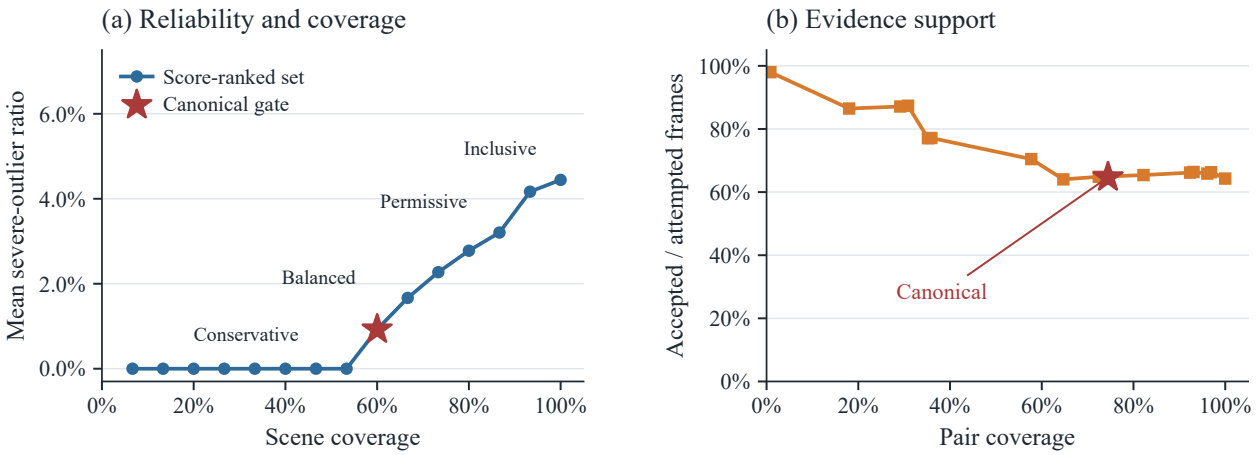

图 9: UAV-TAlign-12K 上的可靠性–覆盖率运行曲线。（a）基于分数排序的曲线刻画场景覆盖率提高时的平均严重离群点比例，星号表示独立的规范 QA 运行点，而非分数排序的前九场景；（b）图像对覆盖率和接受帧支撑给出相应证据范围。连线连接实际观测运行点。

6.6 场景诊断的受控验证

场景诊断量在独立重采样和受控几何扰动下表现出一致响应。五折留帧分析覆盖全部 15 个场景和 75 次共识重计算。每折留出约五分之一的接受帧假设时，15 个场景各自相对完整证据共识的平均位移的中位数为 1.39 像素；这些场景均值的平均值为 2.26 像素。

扰动实验覆盖 45 个代表帧和 675 次受控试验。在每一种扰动类型中，随严重度提高，联合边缘/梯度质量信号的均值均单调下降。在最大扰动严重度下，平移、旋转和尺度扰动引起的平均联合分数变化分别为 -0.074、-0.031 和 -0.025，相应退化比例为 84.4%、80.0% 和 73.3%。表 5 汇总了这些独立证据。图 10 进一步展示逐场景重采样响应和随扰动强度变化的质量趋势。

表 5: 场景共识稳定性与跨模态质量敏感性的受控验证。合成退化比例和联合分数变化均在最大测试严重度下报告。

验证方式	范围	主要响应	退化试验 (%)
留帧共识	15 个场景 / 75 折	1.39 px 场景均值的中位数	–
合成平移	45 帧 / 225 次试验	ΔJoint $= -0.074$	84.4
合成旋转	45 帧 / 225 次试验	ΔJoint $= -0.031$	80.0
合成尺度	45 帧 / 225 次试验	ΔJoint $= -0.025$	73.3

6.7 累加式消融实验

固定 8 场景消融用于分离鲁棒共识和跨模态验证的作用。鲁棒共识将平均边缘增益从 0.124 提高到 0.146，将梯度 NCC 增益从 0.126 提高到 0.149；同时，严重离群点比例从 0.104 降至 0.042，变换离散度从 151.2 像素降至 52.5 像素。跨模态验证进一步把阶段输出映射为规范产品决策。

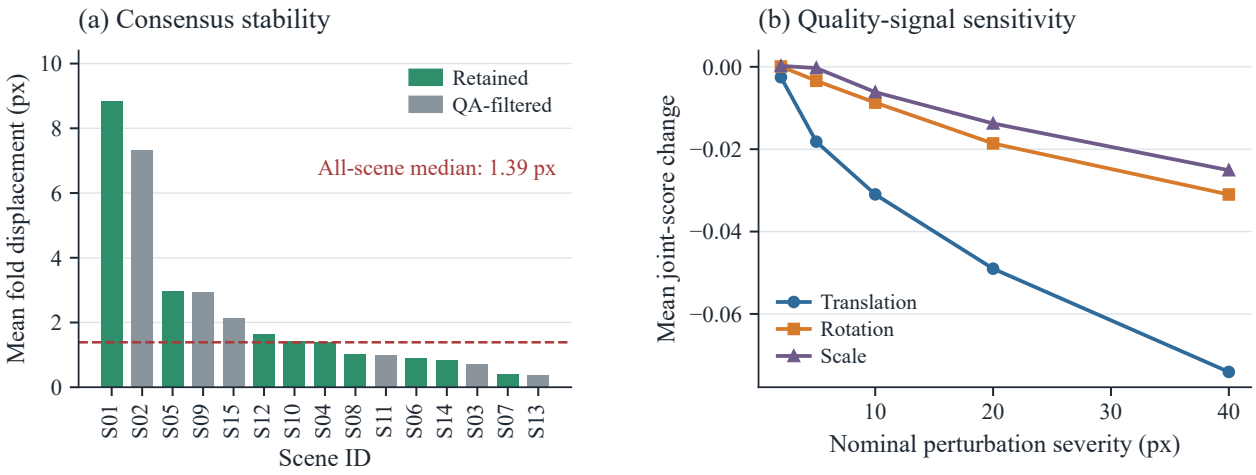

图 10: UAV-TAlign-12K 上的受控验证。（a）各场景的五折留帧平均位移，虚线为场景均值的中位数；（b）每种扰动及强度下 45 帧的平均联合质量变化。

表 6: 固定 8 场景 UAV-TAlign-1K-Lite 子集上的累加式消融。输出/N 在前两行计数可用变换，最后一行计数规范保留场景。诊断均值覆盖每阶段全部八个场景，各阶段均固定均匀选择。

变体	共识	QA	输出 /N	ΔEdge ↑	ΔGrad ↑	Severe ↓	Disp. (px) ↓
仅成对证据	–	–	8/8	0.124	0.126	0.104	151.2
+ 鲁棒场景共识	✓	–	8/8	0.146	0.149	0.042	52.5
+ 跨模态验证	✓	✓	5/8	0.146	0.148	0.042	57.7

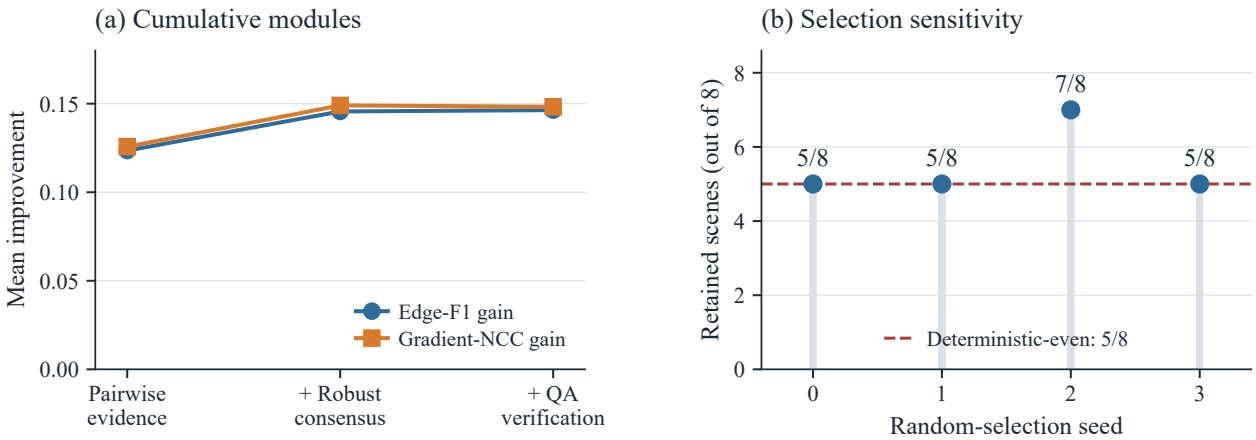

图 11: 固定八场景 UAV-TAlign-1K-Lite 子集上的模块归因。（a）边缘与梯度一致性的累加变化；（b）四个随机种子的规范保留场景数，虚线表示确定性均匀选择参考。

图 11 将累加式模块效应与多随机种子选择分析联系起来：鲁棒共识贡献最大的诊断增益，而确定性调度提供稳定的参考运行策略。

在不同随机选择种子下，同一固定子集得到 5/8 至 7/8 个场景产品，而平均接受帧支撑保持相对稳定。确定性均匀选择提供可复现参考，而随机运行将种子敏感性定位于少量接近阈值的场景。

7 讨论

7.1 从成对证据到场景级几何

UAV-TAlign-12K 揭示了无人机红外-可见光对齐问题中的一个阶段转变。红外专用方法和现代匹配器在正式划分的几乎每一对图像上均能生成单应性，从而提供丰富的几何证据。然而，这些证据在空间支撑、跨模态一致性，以及与同一场景其他帧的一致程度上仍有差异。因此，场景共识是一个独立的对齐阶段：它将异质逐帧估计转化为可作为统一几何产品使用的场景变换。

消融结果表明，鲁棒共识是贡献最显著的模块。相较仅使用成对证据，共识在提高边缘与梯度一致性的同时，大幅降低严重离群点比例和变换离散度。跨模态验证随后把稳定几何映射为规范高置信产品集合。这一组合设计将局部对应关系证据与无人机巡检和多模态感知所需的场景级输出联系起来。

7.2 覆盖率感知的运行分析

可靠性–覆盖率曲线为固定阈值评测增加了运行维度。规范运行点提供 9 个高置信产品，并覆盖 74.4% 的评测图像对；基于分数的扫描则展示更广泛的覆盖区间。应用系统可以据此按照自身质量要求选择场景产品覆盖率，而无需改变成对匹配器或共识估计器。

受控分析检验了相应诊断量。留出一折后重计算共识，得到 1.39 像素的场景平均位移中位数，刻画共识对证据选择的敏感性。平移、旋转与尺度扰动使平均联合边缘/梯度信号逐步下降，刻画其对几何扰动的响应。这些观测支持将共识稳定性与图像一致性作为互补诊断量。

7.3 基准扩展性

该基准通过基于 manifest 的接口分离成对对应关系、场景聚合和跨模态验证，使后续匹配器与共识估计器能够在同一真实采集划分上研究。场景单应性描述主导平面或远场对齐；空间变化几何需要局部或非刚性表示。所报告运行曲线刻画 15 个采集场景内部的相对图像一致性与证据一致性。

确定性证据调度为这一共享接口提供稳定默认策略。多随机种子实验表明，随机选择会改变少量接近阈值场景的产品状态，但接受帧支撑总体保持稳定。因此，证据调度主要承担可复现性作用，而鲁棒共识与跨模态验证构成场景产品生成的核心部分。

8 结论

UAV-TAlign-12K 将真实无人机红外-可见光影像与成对证据、场景共识和运行覆盖率评测联系起来。在其 6,037 对正式划分上，七种基线表明红外专用方法和现代匹配器提供了丰富的单应性证据。后续任务是整合这些证据，并决定哪些场景变换值得保留。UAV-TAlign 为全部 15 个场景生成变换，保留其中 9 个，覆盖 74.4% 的评测图像对。累加式消融表明，

鲁棒共识是图像一致性改善与离散度降低的主要来源；重采样和受控扰动进一步刻画稳定性与诊断敏感性。数据集与参考框架共同将场景级证据整合确立为无人机红外-可见光对齐中明确且可复现的评测目标。

数据可用性

UAV-TAlign-12K 归南宁师范大学与广西大学共同所有，已按知识共享署名 4.0 国际许可协议准备发布。正式评测划分包含 6,039 对候选数据中的 6,037 对完整性检查 RGB-红外图像。图像压缩包尚待存入数据仓库并建立访问链接。独立的复现材料包包含正式 manifest、元数据、完整性汇总、评测代码和定量图源数据，供作为补充材料提交。UAV-TAlign 原创软件采用 Apache-2.0 许可；第三方组件保留各自许可。

A 协议定义与可复现细节

A.1 探针帧与相对质量信号

每个场景从 manifest 中均匀选取至多 12 对图像作为 QA 探针，不仅从已接受匹配中选取。图像以四分之一尺度评测，最长边上限为 640 像素，场景单应性同步转换到评测坐标。每个探针的变换后图像和尺寸匹配参考均在同一个红外变换有效掩膜内评分。参考仅将红外边缘和梯度缩放至 RGB 评测网格，其全图尺寸映射记为 H_0，不是拟合得到的配准。

令 $E_i(H)$ 为具有一像素膨胀容差的边缘重叠 F1，$G_i(H)$ 为有效掩膜内梯度幅值的归一化互相关。定义

$$\delta E_i = E_i(\bar{H}_S) - E_i(H_0), \qquad \delta G_i = G_i(\bar{H}_S) - G_i(H_0). \tag{A.1}$$

场景增益 ΔE_S 和 ΔG_S 是探针均值。严重相对离群帧同时满足 $\delta E_i < -0.01$ 和 $\delta G_i < -0.01$；O_S 为其占探针帧的比例。$p_\vee$ 为任一增益为正的帧比例，p_G 为梯度增益为正的帧比例。这些图像域诊断量衡量相对尺寸匹配参考的一致性。

A.2 支撑与规范验证

帧进入接受池需满足：单应性拟合成功、至少 80 个候选匹配、内点率不低于 0.30、平均内点重投影误差不超过 4 像素、覆盖率不低于 0.25。对于包含 N 对有效图像的场景，固定的最低接受支撑为

$$N_{\min} = \max(4, \min(N, \max(8, \min(20, \mathrm{round}(0.15N))))) \,. \tag{A.2}$$

S01–S04 的阈值为 8，S07 为 15，其余场景为 20。接受支撑 A_S 为接受帧数除以尝试帧数。鲁棒剔除率 J_S 为共识阶段从接受池剔除的比例。离散度 D_S 先在红外图像的 5×5 网格上

计算每个接受假设相对共识的平均位移，再在假设间取中位数，单位为 RGB 图像像素。

主要路径 L_S 要求 $\Delta E_S > 0$、$\Delta G_S > 0$、$p_{\mathrm{V}} \geq 0.60$，且无严重相对离群帧。替代路径 W_S 适用于尺寸初始化的红外输入，且要求同时满足

$$\begin{aligned} A_S &\geq 0.80, & \bar{r}_S &\geq 0.30, & \bar{e}_S &\leq 4 \text{ px}, & \bar{c}_S &\geq 0.25, \\ D_S &\leq 25 \text{ px}, & J_S &\leq 0.25, & O_S &\leq 0.10, & n_{\mathrm{out}} &\leq 1, \\ \Delta E_S &\geq -0.05, & \Delta G_S &> 0, & p_G &\geq 0.60. \end{aligned} \tag{A.3}$$

其中 $\bar{r}_S, \bar{e}_S, \bar{c}_S$ 为接受帧的均值。通过 L_S 给出 pass；未通过 L_S 而通过 W_S 给出 pass with warning。二者在 $N_S \geq N_{\min}$ 时均计入规范保留。自适应扩展在保留条件和 $D_S \leq 25$、$J_S \leq 0.25$ 稳定性检查均满足时停止。遍历完整调度后，最终规范决策仍遵循式 6；停止检查不是主要路径的额外保留条件。因此，提前停止和最终保留承担不同作用。

A.3 归一化可靠性评分

令 $C(x) = \min(1, \max(0, x))$，式 5 中的分量为

$$\begin{aligned} \hat{a}_S &= C(A_S), & \hat{o}_S &= 1 - C(O_S/0.10), \\ \hat{j}_S &= 1 - C(J_S/0.25), & \hat{e}_S &= C((\Delta E_S + 0.05)/0.20), \\ \hat{g}_S &= C(\Delta G_S/0.15), \end{aligned} \tag{A.4}$$

$$\hat{z}_S = 0.5C(\bar{r}_S/0.50) + 0.3C(\bar{c}_S) + 0.2\left[1 - C((\bar{e}_S - 1.5)/1.0)\right]. \tag{A.5}$$

全部常数固定，不对场景结果拟合模型。所得 $[0, 100]$ 评分提供诊断排序，不是校准概率。分数排序覆盖率点选择前 K 个场景，规范运行点则在其独立的保留集合上计算。

A.4 指标汇总

成对统计。 内点率为拟合内点数除以候选匹配数。覆盖率是鲁棒拟合前候选匹配占据的红外图像 16 个网格单元的比例。单对重投影误差为 RGB 图像像素坐标中的平均内点欧氏残差；主表报告这些单对均值的中位数。每个汇总指标使用记录中有限且非空的值：已记录的零内点率和零覆盖率参与汇总，缺失重投影值不参与。运行时间为所声明实现与部署配置下记录的单对时间均值。

场景与条件统计。 场景覆盖率为保留场景比例，图像对覆盖率按各保留场景的有效 manifest 图像对数量加权。接受/尝试比使用指定场景集合中的累加帧数。因此，保留集合支撑为 $1491/2304 = 64.7\%$，全场景支撑为 $2473/3847 = 64.3\%$。条件保留率是场景宏统计，接受支撑是帧微统计。

重采样与扰动。 留帧分析先在每折内计算网格位移均值，再对每个场景的五折取均值。报告的 1.39 像素是 15 个场景均值的中位数；这些场景均值的平均值为 2.26 像素。扰动曲线

对每一强度和类型的 45 帧取联合边缘/梯度分数变化均值。退化率为该设置下联合分数变化为负的帧比例。这两类检验分别评价共识稳定性与质量信号响应，不拟合或重新校准排序评分。

B 数据分布与补充视觉证据

图 B.1 报告逐场景数量和采集属性。图 B.2 与图 B.3 将正文案例扩展到电塔环绕序列及夜间变焦/广角对照。所有可视化使用冻结的变换估计，裁剪范围与对应源记录一致。

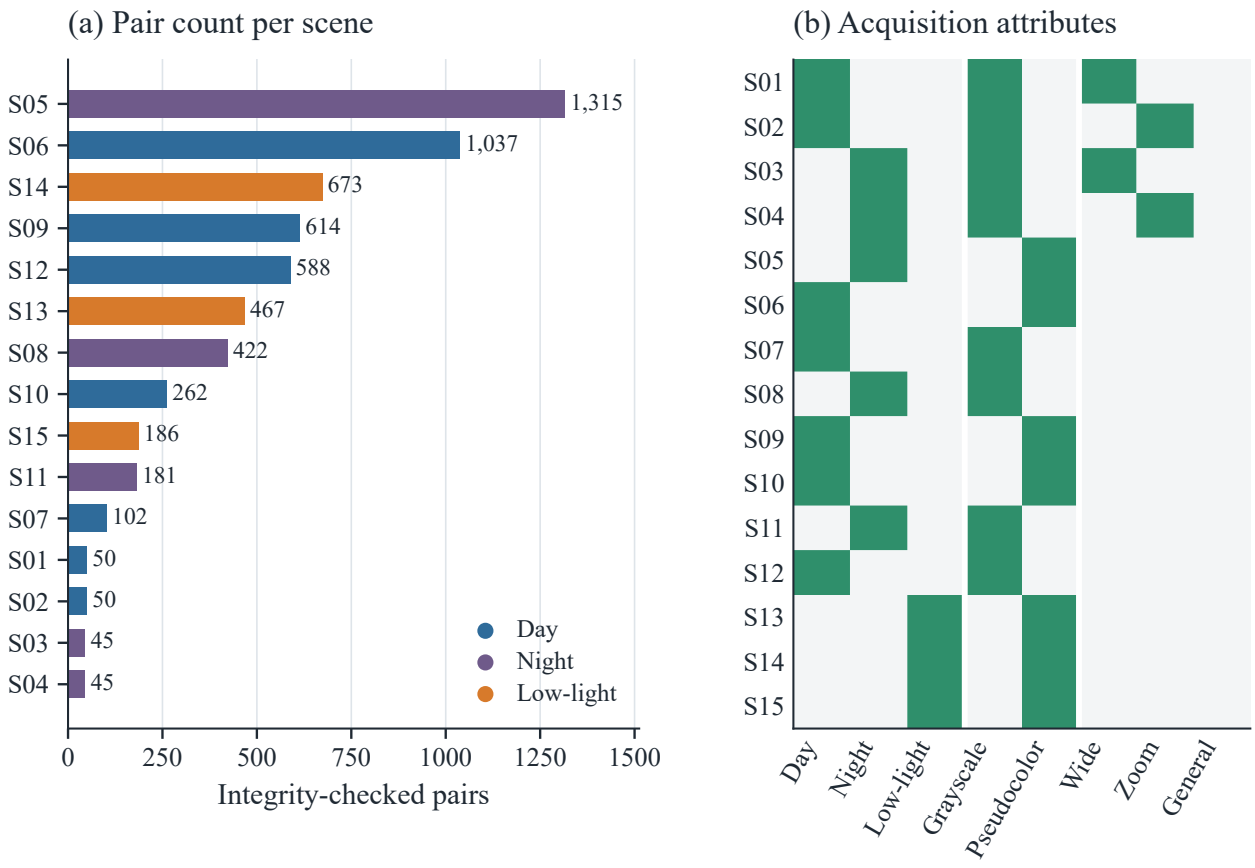

图 B.1: 正式评测划分：（a）15 个场景的有效图像对数量；（b）采集属性。（a）中的颜色表示光照条件，（b）中的填充单元格表示场景属性。

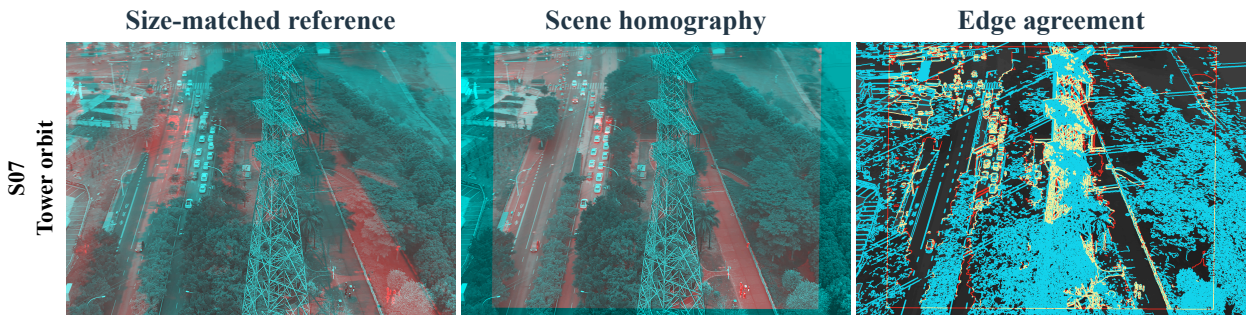

图 B.2: S07 电塔环绕序列的补充规范产品。三个子图在同一显示裁剪范围内比较尺寸匹配参考、场景单应性叠加和边缘一致性。

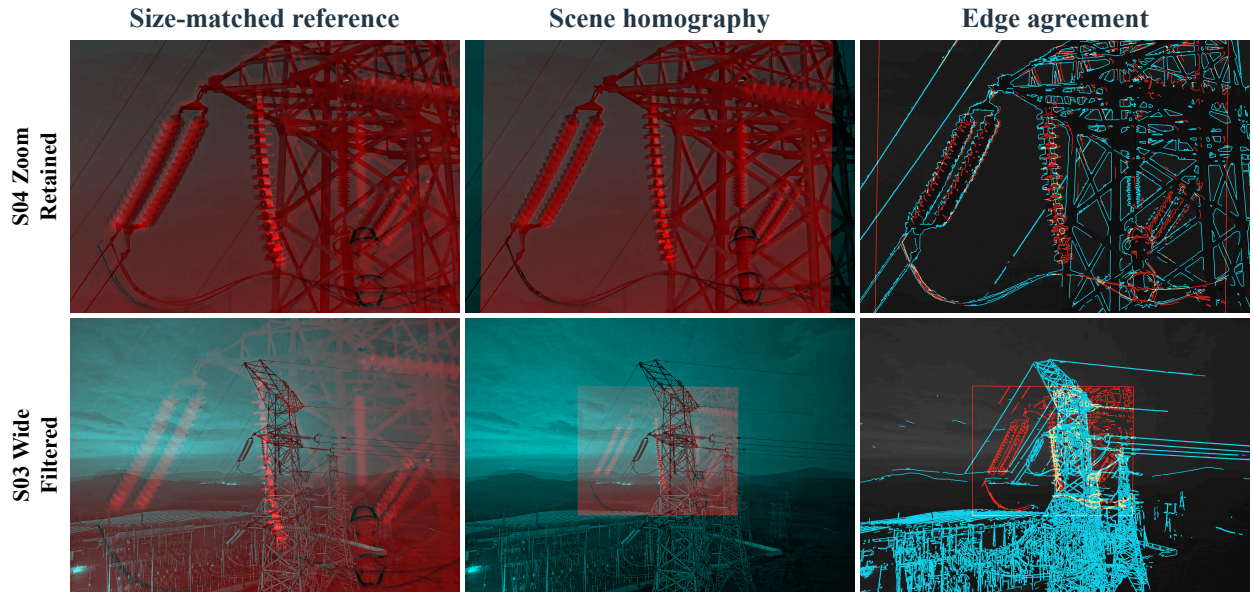

图 B.3: 夜间变焦/广角对照。S04 被规范门控保留，S03 被 QA 过滤。每行展示尺寸匹配参考、估计的场景单应性和边缘一致性。过滤场景的变换保留展示以供检查。

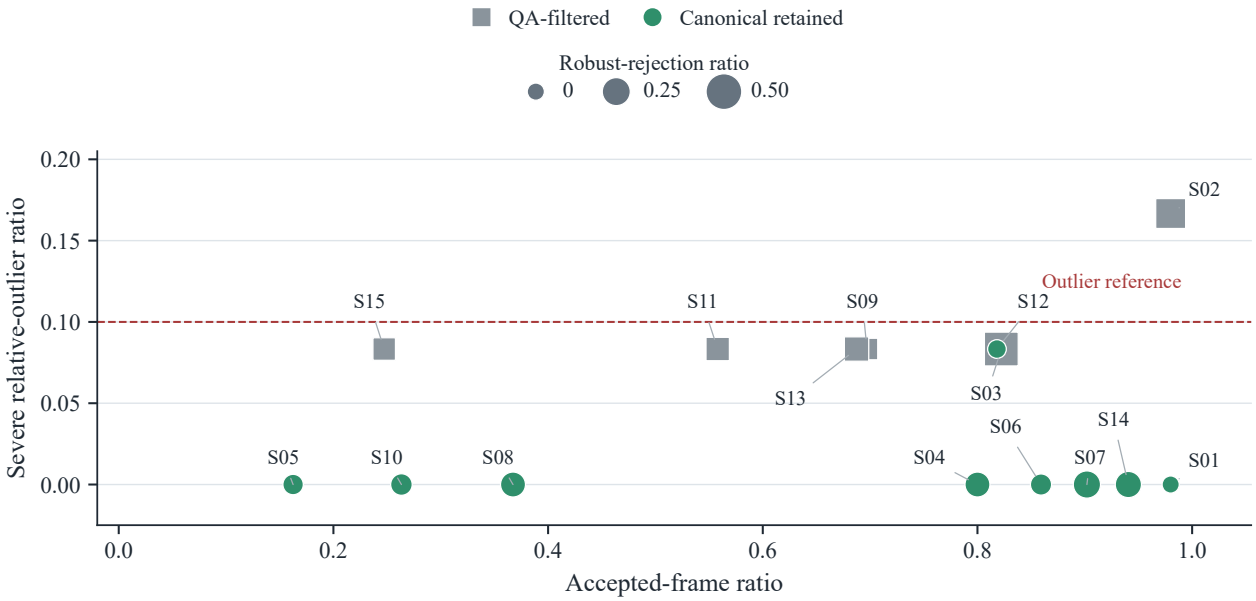

图 B.4: 全场景 QA 诊断。圆点为规范保留场景，方块为 QA 过滤场景；标记大小表示鲁棒剔除比例。虚线表示基线感知路径中使用的 0.10 严重离群比例参考。完整规范决策结合附录 A.2 中的验证路径与支撑要求。

生成式人工智能与人工智能辅助技术声明

OpenAI ChatGPT 与 Codex 用于辅助语言修订、翻译、手稿组织、LaTeX 制作和可编辑示意图布局。AI 辅助代码开发与数据可视化的使用情况已在实验设置中说明。作者承担内容审阅、核验及最终手稿的责任。

参考文献

[1] S. Hwang, J. Park, N. Kim, Y. Choi, I. S. Kweon, Multispectral pedestrian detection: Benchmark dataset and baseline, in: Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2015, pp. 1037–1045.

[2] FLIR Systems, Free FLIR starter thermal dataset for autonomous vehicle testing, original dataset announcement. Accessed 15 October 2026 (2018).
URL https://oem.flir.com/en-in/about/news/flir-open-source-starter-thermal-dataset-for-autonomous-vehicle-testing/

[3] X. Jia, C. Zhu, M. Li, W. Tang, W. Zhou, LLVIP: A visible-infrared paired dataset for low-light vision, in: Proceedings of the IEEE/CVF International Conference on Computer Vision Workshops (ICCVW), 2021, pp. 3489–3497.

[4] J. Liu, X. Fan, Z. Huang, G. Wu, R. Liu, W. Zhong, Z. Luo, Target-aware dual adversarial learning and a multi-scenario multi-modality benchmark to fuse infrared and visible for object detection, in: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2022.

[5] Y. Sun, B. Cao, P. Zhu, Q. Hu, Drone-based RGB-infrared cross-modality vehicle detection via uncertainty-aware learning, IEEE Transactions on Circuits and Systems for Video Technology 32 (10) (2022) 6700–6713.

[6] P. Zhang, J. Zhao, D. Wang, H. Lu, X. Ruan, Visible-thermal UAV tracking: A large-scale benchmark and new baseline, in: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2022, pp. 8876–8885.

[7] C. Li, W. Xue, Y. Jia, Z. Qu, B. Luo, J. Tang, LasHeR: A large-scale high-diversity benchmark for RGBT tracking, IEEE Transactions on Image Processing 31 (2022) 392–404. doi:10.1109/TIP.2021.3130533.

[8] N. Jiang, K. Wang, X. Peng, X. Yu, Q. Wang, J. Xing, G. Li, G. Guo, Q. Ye, J. Jiao, J. Zhao, Z. Han, Anti-UAV: A large-scale benchmark for vision-based UAV tracking, IEEE Transactions on Multimedia 25 (2023) 486–500.

[9] P.-E. Sarlin, D. DeTone, T. Malisiewicz, A. Rabinovich, SuperGlue: Learning feature matching with graph neural networks, in: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2020, pp. 4938–4947.

[10] J. Sun, Z. Shen, Y. Wang, H. Bao, X. Zhou, LoFTR: Detector-free local feature matching with transformers, in: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2021, pp. 8922–8931.

[11] H. Chen, Z. Luo, L. Zhou, Y. Tian, M. Zhen, T. Fang, D. McKinnon, Y. Tsin, L. Quan, ASpanFormer: Detector-free image matching with adaptive span transformer, in: Computer Vision – ECCV 2022, 2022, pp. 20–36.

[12] P. Lindenberger, P.-E. Sarlin, M. Pollefeys, LightGlue: Local feature matching at light speed, in: Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV), 2023.

[13] J. Edstedt, I. Athanasiadis, M. Wadenbäck, M. Felsberg, DKM: Dense kernelized feature matching for geometry estimation, in: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2023, pp. 17765–17775.

[14] J. Edstedt, Q. Sun, G. Bökman, M. Wadenbäck, M. Felsberg, RoMa: Robust dense feature matching, in: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2024, pp. 19790–19800.

[15] Ö. Tuzcuoğlu, A. Köksal, B. Sofu, S. Kalkan, A. A. Alatan, XoFTR: Cross-modal feature matching transformer, in: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops (CVPRW), 2024, pp. 4275–4286.

[16] J. Ren, X. Jiang, Z. Li, D. Liang, X. Zhou, X. Bai, MINIMA: Modality invariant image matching, in: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2025, pp. 23059–23068.

[17] Z. Gao, D. Li, Y. Kuai, R. Chen, G. Wen, Visible-infrared image alignment for UAVs: Benchmark and new baseline, IEEE Transactions on Geoscience and Remote Sensing 63 (2025) 1–14. doi:10.1109/TGRS.2025.3528634.

[18] D. G. Lowe, Distinctive image features from scale-invariant keypoints, International Journal of Computer Vision 60 (2) (2004) 91–110.

[19] H. Bay, A. Ess, T. Tuytelaars, L. V. Gool, SURF: Speeded up robust features, Computer Vision and Image Understanding 110 (3) (2008) 346–359.

[20] E. Rublee, V. Rabaud, K. Konolige, G. Bradski, ORB: An efficient alternative to SIFT or SURF, in: Proceedings of the IEEE International Conference on Computer Vision (ICCV), 2011, pp. 2564–2571.

[21] S. Leutenegger, M. Chli, R. Y. Siegwart, BRISK: Binary robust invariant scalable keypoints, in: Proceedings of the IEEE International Conference on Computer Vision (ICCV), 2011, pp. 2548–2555.

[22] P. F. Alcantarilla, A. Bartoli, A. J. Davison, KAZE features, in: Computer Vision – ECCV 2012, 2012, pp. 214–227.

[23] P. F. Alcantarilla, J. Nuevo, A. Bartoli, Fast explicit diffusion for accelerated features in nonlinear scale spaces, in: Proceedings of the British Machine Vision Conference (BMVC), 2013.

[24] M. A. Fischler, R. C. Bolles, Random sample consensus: A paradigm for model fitting with applications to image analysis and automated cartography, Communications of the ACM 24 (6) (1981) 381–395.

[25] R. Hartley, A. Zisserman, Multiple View Geometry in Computer Vision, 2nd Edition, Cambridge University Press, 2004.

[26] D. Barath, J. Matas, J. Noskova, MAGSAC: Marginalizing sample consensus, in: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2019, pp. 10197–10205.

[27] D. Barath, J. Noskova, M. Ivashechkin, J. Matas, MAGSAC++, a fast, reliable and accurate robust estimator, in: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2020, pp. 1304–1312.

[28] J. Li, Q. Hu, M. Ai, RIFT: Multi-modal image matching based on radiation-variation insensitive feature transform, IEEE Transactions on Image Processing 29 (2020) 3296–3310.

[29] J. Li, P. Shi, Q. Hu, Y. Zhang, RIFT2: Speeding-up RIFT with a new rotation-invariance technique, arXiv preprint arXiv:2303.00319 (2023). doi:10.48550/arXiv.2303.00319.

[30] D. DeTone, T. Malisiewicz, A. Rabinovich, SuperPoint: Self-supervised interest point detection and description, in: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops (CVPRW), 2018, pp. 224–236.

[31] Y. Ono, E. Trulls, P. Fua, K. M. Yi, LF-Net: Learning local features from images, in: Advances in Neural Information Processing Systems, 2018.

[32] M. Dusmanu, I. Rocco, T. Pajdla, M. Pollefeys, J. Sivic, A. Torii, T. Sattler, D2-Net: A trainable CNN for joint detection and description of local features, in: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2019, pp. 8097–8106.

[33] J. Revaud, C. D. Souza, M. Humenberger, P. Weinzaepfel, R2D2: Reliable and repeatable detector and descriptor, in: Advances in Neural Information Processing Systems, 2019.

[34] M. Tyszkiewicz, P. Fua, E. Trulls, DISK: Learning local features with policy gradient, in: Advances in Neural Information Processing Systems, 2020.

[35] H. Germain, G. Bourmaud, V. Lepetit, S2DNet: Learning image features for accurate sparse-to-dense matching, in: Computer Vision – ECCV 2020, 2020, pp. 626–643.

[36] A. Mishchuk, D. Mishkin, F. Radenovic, J. Matas, Working hard to know your neighbor's margins: Local descriptor learning loss, in: Advances in Neural Information Processing Systems, 2017.

[37] Y. Tian, B. Fan, F. Wu, L2-Net: Deep learning of discriminative patch descriptor in euclidean space, in: Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2017, pp. 6128–6136.

[38] Y. Tian, X. Yu, B. Fan, F. Wu, H. Heijnen, V. Balntas, SOSNet: Second order similarity regularization for local descriptor learning, in: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2019, pp. 11016–11025.

[39] I. Rocco, M. Cimpoi, R. Arandjelovic, A. Torii, T. Pajdla, J. Sivic, Neighbourhood consensus networks, in: Advances in Neural Information Processing Systems, 2018, pp. 1658–1669.

[40] Q. Zhou, T. Sattler, L. Leal-Taixé, Patch2Pix: Epipolar-guided pixel-level correspondences, in: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2021, pp. 4669–4678.

[41] W. Jiang, E. Trulls, J. Hosang, A. Tagliasacchi, K. M. Yi, COTR: Correspondence transformer for matching across images, in: Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV), 2021, pp. 6207–6217.

[42] Y. Wang, X. He, S. Peng, D. Tan, X. Zhou, Efficient LoFTR: Semi-dense local feature matching with sparse-like speed, in: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2024, pp. 21666–21675.

[43] H. Jiang, A. Karpur, B. Cao, Q. Huang, A. Araújo, OmniGlue: Generalizable feature matching with foundation model guidance, in: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2024, pp. 19865–19875.

[44] C.-H. Chang, C.-N. Chou, E. Y. Chang, CLKN: Cascaded lucas-kanade networks for image alignment, in: Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2017, pp. 2213–2221.

[45] L. Nie, C. Lin, K. Liao, S. Liu, Y. Zhao, Unsupervised deep image stitching: Reconstructing stitched features to images, CoRR abs/2106.12859 (2021).

[46] K. Bin, C. Chen, T. Hu, J. Qi, P. Zhong, ATR-UMMIM: A benchmark dataset for UAV-based multimodal image registration under complex imaging conditions, arXiv preprint arXiv:2507.20764 (2025). arXiv:2507.20764.

[47] C.-E. Vasile, C. Bîră, R. Hobincu, UAV-TIRVis: A benchmark dataset for thermal–visible image registration from aerial platforms, Journal of Imaging 11 (12) (2025) 432. doi:10.3390/jimaging11120432.

[48] J. Ma, X. Jiang, A. Fan, J. Jiang, J. Yan, Image matching from handcrafted to deep features: A survey, International Journal of Computer Vision 129 (1) (2021) 23–79.

[49] Y. Jin, D. Mishkin, A. Mishchuk, J. Matas, P. Fua, K. M. Yi, E. Trulls, Image matching across wide baselines: From paper to practice, International Journal of Computer Vision 129 (2) (2021) 517–547.

[50] DJI, Zenmuse H30 Series: Specifications, accessed 20 October 2026.
URL https://enterprise.dji.com/zenmuse-h30-series/specs

[51] I. C. Yagmur, RIFT2 multimodal matching: Python implementation, evaluated revision 7d92f00. Accessed 15 October 2026.
URL https://github.com/canyagmur/RIFT2-multimodal-matching-rotation-python